

Skatlaz Server AI 2.0 Beta - Documentação

Visão geral

Servidor Django para IA generativa com administração, RAG, agentes, Ollama, Google Gemini, WebDiver e geração de pacotes LoRA/QLoRA para exportação ao Ollama.

Arquitetura

Pergunta do usuário -> Agente -> RAG/WebDiver -> Provedor LLM -> Logs no banco -> Resposta.

Administração

O painel Django Admin gerencia provedores LLM, templates de prompt, categorias de agentes, coleções RAG, documentos, tarefas WebDiver, datasets, jobs LoRA/QLoRA e sessões de chat.

RAG

Upload de TXT, CSV, JSON, HTML, PDF e DOCX. Indexe com `/ai/rag/index-source/` ou `python manage.py skatlaz_index_rag`.

WebDiver

Crie tarefas com URL e tipo `_text`, `_html`, `_filter` ou `_download`. O resultado pode alimentar uma coleção RAG.

LoRA/QLoRA

O Django gera script QLoRA e Modelfile. O treinamento real deve rodar fora do processo web, em worker ou máquina GPU.

Comandos / Commands

```
pip install -r requirements.txt
python manage.py migrate
python manage.py createsuperuser
python manage.py skatlaz_seed_ai
python manage.py runserver
```